

UNIVERSIDADE FEDERAL DO RIO DE JANEIRO

Data driven Models and Machine Learning

ANDERSON MARDEN DE SOUSA SILVA

**Aplicação de aprendizado de máquina na classificação da
gravidade de acidentes em rodovias federais brasileiras**

RIO DE JANEIRO

2026

Resumo

Acidentes rodoviários com mortos ou feridos graves exigem resposta rápida e uso adequado dos recursos disponíveis. Neste trabalho, avaliei algoritmos de classificação para estimar a gravidade de acidentes registrados em rodovias federais brasileiras, utilizando características da ocorrência, da via e do ambiente. Foram analisados 632.667 registros disponibilizados pela Polícia Rodoviária Federal (PRF), referentes ao período de 2017 a 2025. Os dados de 2017 a 2023 foram usados para treinamento, o ano de 2024 para validação e calibração, e 2025 para o teste final. Foram comparados regressão logística, Random Forest e HistGradientBoosting. O último apresentou o melhor resultado, com PR-AUC de 0,524 e ROC-AUC de 0,711 no teste. Com o limiar definido na validação, foram obtidos precisão de 41,9%, recall de 64,5% e F1 de 0,508. Embora a precisão seja limitada, as 20% ocorrências de maior probabilidade concentraram 39,0% dos acidentes graves e apresentaram precisão de 55,1%. Os resultados indicam que o modelo pode ser útil como prova de conceito para priorização de ocorrências, mas não deve substituir protocolos de atendimento nem decisões humanas.

Palavras-chave: segurança viária; acidentes rodoviários; classificação; aprendizado de máquina; engenharia de transportes.

1 Introdução

A segurança viária é um tema importante da engenharia de transportes, pois envolve aspectos de infraestrutura, operação das vias, comportamento dos usuários e atendimento às ocorrências. Quando um acidente é comunicado, uma das dificuldades é estimar rapidamente a sua gravidade e direcionar os recursos necessários. Informações como localização, tipo do acidente, quantidade de veículos e condições da via podem ajudar nessa avaliação inicial.

O problema investigado neste projeto foi o seguinte: é possível identificar acidentes com mortos ou feridos graves usando informações da ocorrência, da via e do ambiente disponíveis no atendimento inicial? A proposta não é prever onde um acidente acontecerá. O modelo recebe um acidente que já foi registrado e estima a probabilidade de ele pertencer à classe grave. Dessa forma, a aplicação estudada está relacionada à triagem e à priorização de atendimento.

O objetivo geral foi desenvolver e avaliar um modelo de classificação reproduzível para a gravidade de acidentes em rodovias federais. Como objetivos específicos, procurei reunir dados oficiais de vários anos, construir um alvo binário, evitar o uso indevido de informações sobre as vítimas, comparar diferentes algoritmos e avaliar os resultados em um período posterior ao treinamento. Além do desempenho estatístico, também foi analisado um cenário no qual apenas uma parte das ocorrências poderia receber prioridade máxima.

2 Base de dados e definição do problema

2.1 Fonte e organização dos dados

Foram utilizados os arquivos de acidentes agrupados por ocorrência publicados no portal de dados abertos da PRF [1]. Segundo a documentação do órgão, os registros são provenientes do sistema BAT, utilizado a partir de 2017. Por isso, optei por trabalhar com o intervalo de 2017 a 2025, sem misturar dados de sistemas anteriores. O significado das variáveis foi consultado no dicionário de dados da PRF [2].

Os nove arquivos possuem o mesmo esquema, com 30 colunas. Após a leitura, padronização dos nomes e união das bases, foram obtidas 632.667 ocorrências. A Figura 1 apresenta a proporção de acidentes classificados como graves em cada ano. No conjunto de teste de 2025, essa proporção foi de 28,25%.




Figura 1: Quantidade e proporção de acidentes graves por ano. Fonte: elaboração própria a partir dos dados da PRF.

2.2 Variável-alvo e cuidados com vazamento

Foi criado um problema de classificação binária. Uma ocorrência foi considerada grave quando apresentou pelo menos uma morte ou uma pessoa ferida gravemente, conforme a Equação 1.

$$\text{grave} = (\text{mortos} > 0) \vee (\text{feridos graves} > 0). \quad (1)$$

As colunas utilizadas para criar o alvo foram removidas antes do treinamento. Também foram excluídas as demais contagens de vítimas e pessoas, a classificação final do acidente e o identificador da ocorrência. Esse cuidado é necessário porque essas variáveis revelariam direta ou indiretamente a resposta esperada, produzindo um desempenho artificialmente alto. A causa declarada também foi retirada, pois pode ser determinada somente depois da investigação.

Por outro lado, o tipo do acidente e a quantidade de veículos foram mantidos. A hipótese adotada é que essas duas informações podem estar disponíveis durante a comunicação inicial. Portanto, o cenário de uso começa depois que o acidente ocorreu e foi notificado. Essa definição é uma limitação importante do projeto e evita apresentar o modelo como ferramenta de prevenção anterior ao acidente.

3 Metodologia

3.1 Preparação e divisão temporal

Foram empregados 18 atributos. Entre os categóricos estão dia da semana, unidade federativa, rodovia, tipo de acidente, fase do dia, sentido da via, condição meteorológica, tipo de pista, traçado e uso do solo. Os numéricos incluem quilômetro, quantidade de veículos, latitude, longitude e transformações cíclicas da hora e do mês. As transformações por seno e cosseno foram utilizadas porque horas e meses possuem comportamento circular.

Na regressão logística, as categorias foram convertidas por codificação *one-hot*, e os valores numéricos foram padronizados. Nos modelos baseados em árvores, foi utilizada codificação ordinal, incluindo tratamento para categorias desconhecidas. Valores numéricos ausentes foram preenchidos com a mediana calculada apenas no conjunto de treinamento. A implementação foi feita em Python com as bibliotecas pandas, NumPy, Matplotlib, Seaborn e scikit-learn [3].

Em vez de uma divisão aleatória, foi utilizada uma separação temporal, mostrada na Tabela 1. Essa escolha representa melhor uma aplicação real, em que dados do passado são

utilizados para gerar previsões futuras, e reduz a chance de registros muito próximos aparecerem nos dois lados da avaliação.

Tabela 1: Divisão temporal da base de dados.

Conjunto	Período	Número de ocorrências
Treinamento	2017–2023	486.982
Validação	2024	73.156
Teste	2025	72.529

3.2 Modelos e critérios de avaliação

Foram comparados três algoritmos supervisionados: regressão logística, Random Forest e HistGradientBoosting. A regressão logística foi escolhida como modelo linear e mais fácil de interpretar. A Random Forest combina várias árvores treinadas sobre amostras e subconjuntos de atributos. Já o HistGradientBoosting constrói árvores em sequência, buscando corrigir os erros anteriores. Também foi incluído um baseline que atribui a todos os exemplos a prevalência da classe grave. Nos modelos supervisionados foram usados pesos de classe para aumentar a atenção aos acidentes graves.

O modelo foi escolhido pela área sob a curva precisão–recall (PR-AUC) na validação de 2024. Essa métrica recebeu maior importância porque a classe grave é minoritária e o interesse principal está no desempenho sobre ela. Também foram calculados ROC-AUC, precisão, recall, F1, F2, acurácia balanceada, Brier score e matriz de confusão. A acurácia comum não foi usada como critério principal: em 2025, um modelo que previsse todos os casos como não graves teria 71,75% de acurácia, porém não encontraria nenhum acidente grave.

Após a seleção, foi aplicada calibração sigmoide usando os dados de 2024. O objetivo foi aproximar as probabilidades previstas das frequências observadas. O limiar de decisão que maximizou o F1 na validação foi 0,259. Tanto a calibração quanto o limiar foram definidos sem consultar os resultados de 2025. Por fim, intervalos de confiança de 95% foram estimados por 400 reamostragens bootstrap no conjunto de teste.

4 Resultados

4.1 Comparação dos classificadores



Na validação de 2024, o HistGradientBoosting apresentou PR-AUC de 0,534, seguido pela Random Forest, com 0,529, e pela regressão logística, com 0,520. Assim, o HistGradientBoosting foi selecionado. A calibração reduziu o Brier score de validação de 0,211 para 0,174, indicando probabilidades mais coerentes com as frequências observadas.

A Tabela 2 mostra a avaliação final em 2025. O modelo escolhido manteve o melhor resultado de PR-AUC, com 0,524, contra 0,283 do baseline. A diferença entre o modelo escolhido e as outras técnicas não foi grande, mas o ganho em relação ao baseline foi claro.

Tabela 2: Resultados no conjunto de teste de 2025.

Modelo	PR-AUC	ROC-AUC	Precisão	Recall	F1
HistGradientBoosting	0,524	0,711	0,419	0,645	0,508
Random Forest	0,519	0,705	0,486	0,489	0,488
Regressão logística	0,510	0,700	0,436	0,575	0,496
Baseline	0,283	0,500	0,000	0,000	0,000

O HistGradientBoosting identificou 13.211 dos 20.493 acidentes graves. Ao mesmo tempo, deixou de identificar 7.282 casos graves e gerou 18.322 falsos positivos. A acurácia balanceada foi de 64,6%. A PR-AUC apresentou intervalo de confiança de 95% entre 0,517 e 0,532. Para a ROC-AUC, o intervalo foi de 0,707 a 0,715, e para o F1 foi de 0,503 a 0,513.

**Figura 2:** Curva precisão-recall em 2025.**Figura 3:** Matriz de confusão do modelo escolhido.

4.2 Análise da precisão e priorização

A precisão de 41,9% no limiar escolhido pode ser considerada baixa: entre 100 ocorrências classificadas como graves, aproximadamente 42 realmente pertencem à classe. Esse resultado significa que há muitos falsos positivos. Entretanto, o limiar foi escolhido para equilibrar precisão e recall, e o modelo identificou 64,5% dos graves. Aumentar o limiar melhoraria a precisão, mas também faria o sistema deixar de reconhecer mais acidentes graves. Por exemplo, a Random Forest teve precisão maior, de 48,6%, mas encontrou apenas 48,9% dos graves.

Como alternativa mais compatível com uma capacidade limitada de atendimento, as ocorrências foram ordenadas pela probabilidade prevista. Ao selecionar somente as 20% com maior probabilidade, esse grupo concentrou 39,0% de todos os acidentes graves e apresentou precisão de 55,1%. A concentração foi 1,95 vez a prevalência geral. Uma seleção aleatória de 20% capturaria, em média, aproximadamente 20% dos casos graves. Portanto, considero a ordenação de risco mais útil para interpretar o resultado do que uma decisão rígida entre grave e não grave.




Figura 4: Proporção acumulada de acidentes graves conforme a capacidade de priorização.

4.3 Importância, ablação e calibração

A importância por permutação mede a queda de desempenho ao embaralhar um atributo. As variáveis mais importantes foram tipo do acidente, quantidade de veículos, BR, UF, traçado da via e uso do solo. Isso não demonstra uma relação de causa e efeito; apenas indica quanto a previsão depende de cada informação dentro da base analisada.

Também foi realizado um estudo de ablação para verificar a dependência das informações da comunicação inicial. Quando tipo do acidente e quantidade de veículos foram retirados, a PR-AUC caiu de 0,524 para 0,396, uma redução relativa de 24,4%, e a ROC-AUC caiu de 0,711 para 0,629. O resultado reforça que o modelo completo é adequado apenas para o cenário posterior à notificação e não para prever a gravidade antes que o acidente aconteça.




Figura 5: Importância dos atributos por permutação.




Figura 6: Curva de calibração no teste.

No teste, o Brier score do modelo calibrado foi 0,176, enquanto o baseline obteve 0,203. A Figura 6 mostra que a calibração aproximou as probabilidades da diagonal ideal. Mesmo assim, uma aplicação real exigiria acompanhamento periódico, pois a distribuição dos acidentes pode mudar com o tempo e variar entre regiões.

5 Discussão

Os resultados mostram que existe informação útil nas características iniciais das ocorrências, mas o problema continua difícil. A PR-AUC de 0,524 é bem superior à prevalência de 0,283, porém está distante de um classificador perfeito. Além disso, a precisão de 41,9% impede afirmar

que toda ocorrência sinalizada pelo modelo é realmente grave. Para uma aplicação de segurança, também merece atenção o fato de 35,5% dos casos graves não terem sido encontrados no limiar adotado.

Apesar dessas limitações, o cenário de priorização apresentou um resultado prático: concentrar 39,0% dos acidentes graves em 20% dos registros. O uso mais razoável seria como informação adicional para apoiar uma equipe, junto com protocolos existentes e dados atualizados, e não como decisão automática de envio ou recusa de atendimento. O custo de um falso negativo tende a ser maior, mas muitos falsos positivos também podem sobrecarregar as equipes. Assim, o limiar deveria ser escolhido de acordo com a capacidade operacional e não apenas por uma métrica matemática.

Outra limitação é que a base contém acidentes registrados, mas não informa quantos veículos circularam em cada trecho. Dessa forma, não é correto concluir que uma rodovia é mais perigosa somente porque possui mais ocorrências: ela também pode ter maior volume de tráfego. Da mesma maneira, as importâncias não permitem afirmar que um atributo causa maior gravidade. Diferenças de preenchimento entre anos ou regiões também podem afetar os padrões aprendidos.

A proximidade entre os três modelos mostra que usar um algoritmo mais complexo não resolveu completamente o problema. Trabalhos futuros poderiam incluir volume de tráfego, distância até hospitais e bases de atendimento pré-hospitalar, geometria mais detalhada da rodovia e dados meteorológicos externos. Também seria importante avaliar o desempenho separadamente por estado, investigar possíveis desigualdades regionais e recalibrar o modelo com dados mais recentes.

6 Conclusão

Neste projeto, desenvolvi uma aplicação de aprendizado de máquina para classificar a gravidade de acidentes em rodovias federais brasileiras. A separação temporal permitiu avaliar o modelo em um ano posterior ao treinamento. Entre os algoritmos testados, o HistGradientBoosting calibrado apresentou o melhor resultado, com PR-AUC de 0,524, ROC-AUC de 0,711, Brier score de 0,176 e recall de 64,5% no teste de 2025.

O desempenho deve ser considerado moderado. A precisão no limiar escolhido foi de 41,9%, mostrando que ainda há uma quantidade relevante de falsos positivos. Por outro lado, ao priorizar 20% das ocorrências, foi possível concentrar 39,0% dos acidentes graves, com precisão de 55,1%. Assim, a principal contribuição do modelo é a capacidade de ordenar ocorrências por risco, e não substituir a análise humana por uma classificação definitiva.

Concluo que a abordagem é útil como prova de conceito para apoio à priorização, desde que suas limitações sejam claramente reconhecidas. O projeto também mostrou a importância de evitar vazamento de dados, respeitar a ordem temporal, comparar com um baseline e analisar os erros, em vez de avaliar o trabalho somente pela acurácia.

Referências

- [1] POLÍCIA RODOVIÁRIA FEDERAL. **Dados abertos da PRF**. Brasília, DF, [s.d.]. Disponível em: <https://www.gov.br/prf/pt-br/aceso-a-informacao/dados-abertos/dados-abertos-da-prf>. Acesso em: 19 jul. 2026.
- [2] POLÍCIA RODOVIÁRIA FEDERAL. **Dicionário de dados: acidentes**. Brasília, DF, [s.d.]. Disponível em: <https://www.gov.br/prf/pt-br/aceso-a-informacao/dados-abertos/>

[dicionario-acidentes](#). Acesso em: 19 jul. 2026.

- [3] PEDREGOSA, F. et al. Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, v. 12, p. 2825–2830, 2011.